Analiza podataka

Pri treniranju modela stojnog učenja vrlo je važna obrada i analiza samog seta podataka nad kojim se provodi proces treniranja modela.
U datoteci analiza, unutar foldera student može se vidjeti proces analize seta podataka koji će biti pobliže opisan u ovom dokumentu.

Početna obrada

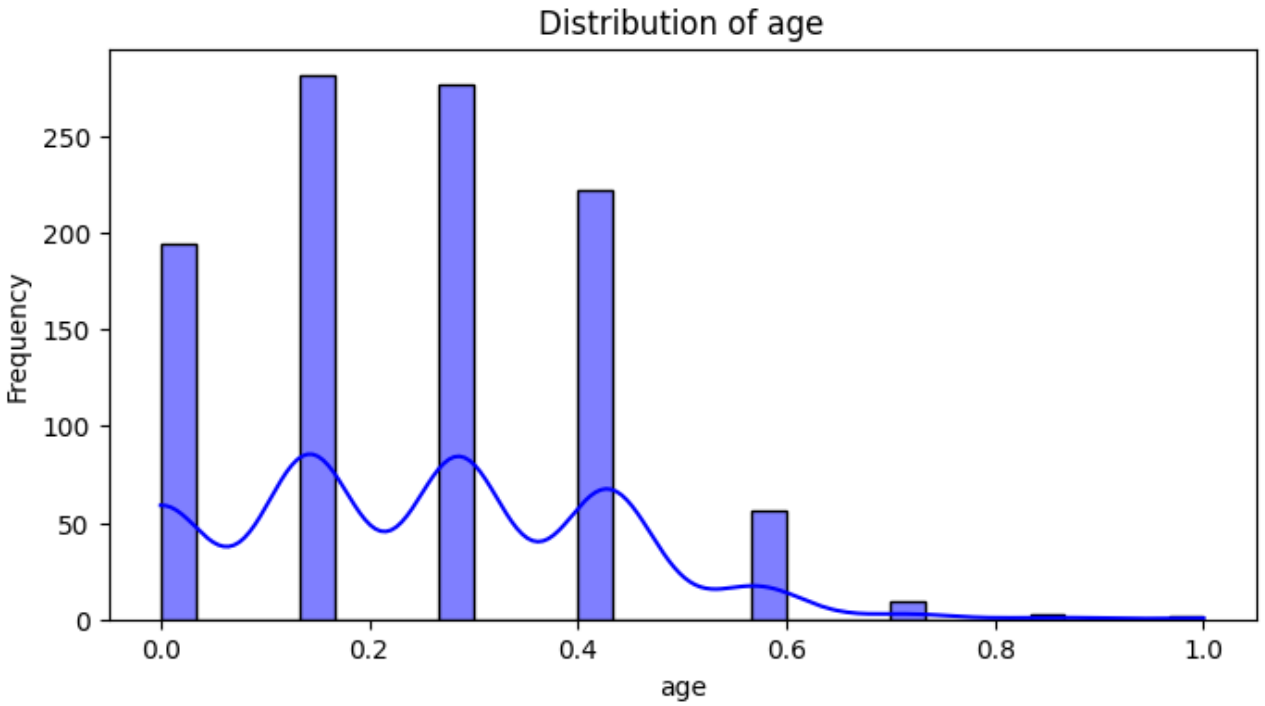
Za početak se učitaju oba seta (i za matematiku i za portugalski jezik) te se spoje u jedan set.
Ispisali smo broj redaka i stupaca u spojenom setu podaka: (1044, 33).
Iz toga vidimo da imamo 1044 stupaca koji predstavljaju podatak jednog studenta, te 33 retka koji predstavljaju varijable za koje su upisane vrijednosti kao što su naprimjer: škola, spol, posao oca, posao majke…
Varijable su različitih tipova, no uglavnom su ili objekt ili int64.

Zatim je odrađena normalizacija i numeracija podataka kako bi bili podležni treniranju modela. Naim modeli stojnog učenja mogu raditi samo nad numeričkim podatcima. Za varijable binarnih vrijednosti (da/ne) koristili smo Label enocding koji ih pretvara u 0 ili 1. One-hot encoding korišten je za kategoričke vrijednosti. Tim procesom se svakoj od kategorija pridjeljuje frekvencija pojavljivanja. Numeričke vrijednosti su skalirane pomoću MinMaxScaler procesa.

Nakon obrade podataka, provjereno je postoji li null vrijednosti, tj nedostaju li za neke varijable podatci. Obradom je utvrđeno da nema vrijednosti koje nedostaju.

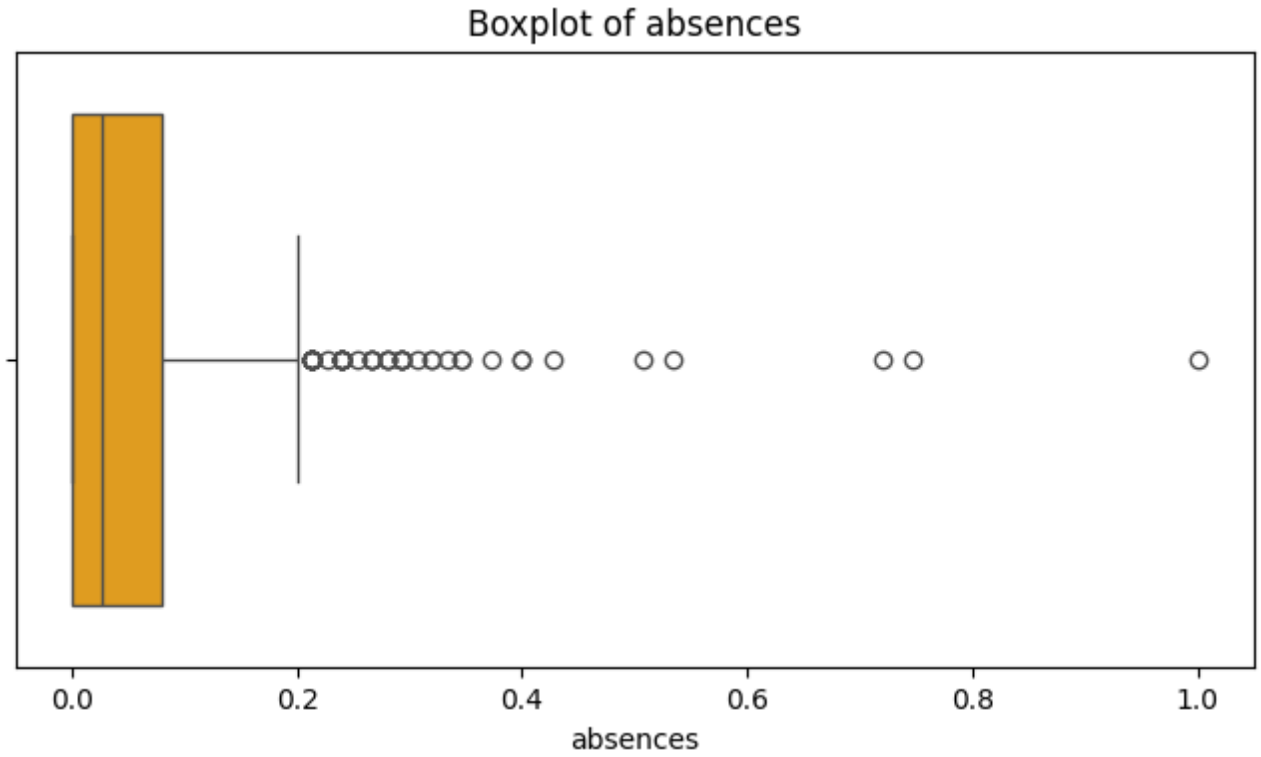
Distribucija varijabli

Zatim je generirano nekoliko grafova koji prikazuju distribuciju numeričkij varijabli.
Primjer jednog grafa je za distirbuciju vrijednosti godina. Na grafu vidimo frekvenciju pojavljanja određene dobi unutar seta podataka. Naravno, na ovom grafu vrijednosti se kreću od 0.0 do 1.0 iz razloga što su podatci prethodno obrađeni i skalirani.



Boxplot

Idući korak je bio potražiti ekstremne vrijednosti koristeći boxplot funkciju. Za rezultate su također generirani grafovi. Boxplot grafovi prikazuju pravokutnih koji predstavlja 50% svih podataka, dok linija unutar pravoknika označava srednju vrjednost. Linije koje su produžene iz pravonutika obuhvaćaju preostale vrijednosti iz seta podataka, koje i dalje padaju unutar nekog okvira. Točke koje stoje samostalno van svih okvira na grafu predstavljaju ekstreme vrijednosti.
Analizom grafa možemo uočiti da gotovo svaka varijabla ima ekstreme koji izlaze van nekih okvira. Na primjer varijabla godina ima dvije točke na grafu što znači da postoje dva ekstrema. Najvise ekstrema ima varijabla izostanaka. No iz izgleda okvira možemo zaključiti da vrijednosti te varijable nisu prikladne za pronalaženje srednje vrijednosti i ekstrema, tako da ti ekstremi nebi trebali predstavljati veliki problem pri treniranju modela



IQR metoda

Traženje ekstremnih vrijednosti također je odrađeno koristeći IQR metodu. Extremnim vrijednostima se smatraju one koje padaju van opsega: (Q1 - 1.5 * IQR) - (Q3 + 1.5 * IQR). Q1 je 25% percentil, Q3 je 75% precentil, a IQR razlika između njih.
Iz rezultata je moguće zaključiti da varijable uglavnom imaju samo nekoliko ekstrema ili ih nemaju opće. Neke varijable imaju veliki broj ekstrema, čak i preko njih 50. Predpostavka je da se u tim slučajevima radi o varijablama podležnim ekstremima, kao što su izostanci, nagativne ocjene i slično. Takve varijable i njihove ekstremene vrijednosti nebi trebale predstavljati veliki problem pri treniranju modela.

```
Detecting outliers using the IQR method...

age:
  - Median value: 0.2857142857142856
  - Number of outliers: 5
  - Outliers:
[1.0, 0.8571428571428572, 1.0, 0.8571428571428572, 0.8571428571428572]
  - Most extreme outlier value: 1.0 at index 247

Medu:
  - Median value: 0.75
  - No outliers detected.

Fedu:
  - Median value: 0.5
  - No outliers detected.

traveltime:
  - Median value: 0.0
  - Number of outliers: 24
  - Outliers:
[1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0]
  - Most extreme outlier value: 1.0 at index 61
```

Matrica korelacije

Pomoću matrice korelacije prikazana je međuovisnost parova varijabli. Crvena pokazuje veću ovisnost između varijabli (negativna/pozitivna), dok plava prikazuje najmanje ovisnosti. Kao što se vidi na grafu na dijagonali je najveća ovisnoti (varijabla u ovisnoti sama sa sobom). Također se može zaključiti da varijable koje predstavljaju ocjene (G1, G2, G3) imaju najveću razinu međuovisnoti.

