Klasifikacijski modeli

Uvod

U današnjem svijetu analize podataka, strojno učenje pruža snažan alat za rješavanje različitih zadataka, od prepoznavanja slika do predviđanja budućih događaja. Jedan od najčešćih zadataka u strojnim učenjima je klasifikacija, gdje je cilj podijeliti podatke u različite kategorije ili klase na temelju njihovih značajki. U ovom radu fokusiramo se na usporedbu različitih klasifikacijskih modela primijenjenih na podatke o učenicima, s ciljem predviđanja njihovih obrazovnih rezultata na temelju različitih ulaznih značajki. Specifično, analiziramo dvije glavne vrste klasifikacija: binarnu i višerazinsku klasifikaciju, primjenjujući tri različita modela strojnog učenja: Logističku regresiju, Random Forest Classifier i Support Vector Machines (SVM). Analizirali smo dva skupa podataka koji sadrže informacije o učenicima – jedan za matematiku, a drugi za portugalski jezik – te ih kombinirali kako bismo ispitali učinak različitih skupova podataka na rezultate modela.

Vrste klasifikacije

U ovom istraživačkom radu provodimo dvije vrste klasifikacije:

- Binarna klasifikacija: U ovom tipu klasifikacije cilj je predvidjeti pripadnost jednog od dvaju mogućih ishodnih stanja. Na primjer, u kontekstu ovog rada, predviđamo hoće li učenik imati višu ili nižu ocjenu od određenog praga (npr. 0.5), što se klasificira u dvije kategorije: "prolaz" i "pad".
- Višerazinska klasifikacija: Ovdje se predviđa pripadnost jednoj od više od dvije klase. U ovom radu, podjela ocjena učenika na 5 razina uspjeha (na temelju konačne ocjene) omogućuje nam da modelira učenike u nekoliko kategorija, od najlošijih do najboljih.

Usporedba modela na temelju algoritma strojnog učenja

Logistička regresija

Binarna klasifikacija

```
Accuracy: 0.9090909090909091
Precision: 0.905511811023622
Recall: 0.9426229508196722
F1-Score: 0.9236947791164659
AUC-ROC: 0.9023459581684568
Log-Loss: 0.2732236956885388
```

5-razinska klasifikacija

```
Accuracy: 0.6363636363636364
Precision (Macro): 0.6283895483213852
Recall (Macro): 0.39906454361241595
F1-Score (Macro): 0.42179030526819616
AUC-ROC (Micro): 0.7727272727272727
Log-Loss: 0.8464557136940638
```

Random forest classifier

Binarna klasifikacija

```
Accuracy: 0.9425837320574163
Precision: 0.9435483870967742
Recall: 0.9590163934426229
F1-Score: 0.9512195121951219
AUC-ROC: 0.9392783116638402
Log-Loss: 0.2262969046319785
```

5-razinska klasifikacija

```
Accuracy: 0.7894736842105263
Precision (Macro): 0.8284183970751136
Recall (Macro): 0.6541833609652759
F1-Score (Macro): 0.7123628144346494
AUC-ROC (Micro): 0.868421052631579
Log-Loss: 0.5559213185350103
```

Support Vector Machine

Binarna klasifikacija

```
Accuracy: 0.9090909090909091
Precision: 0.8931297709923665
Recall: 0.9590163934426229
F1-Score: 0.924901185770751
AUC-ROC: 0.899048426606369
Log-Loss: 1.0351098607260971
```

5-razinska klasifikacija

```
Accuracy: 0.7368421052631579
Precision (Macro): 0.7691606622062104
Recall (Macro): 0.557061112646219
F1-Score (Macro): 0.6124294196049921
AUC-ROC (Micro): 0.8355263157894738
Log-Loss: 0.004018077931078971
```

Za početak usporedit ćemo performanse korištenih modela strojnog učenja na temelju nekoliko ključnih metrika. Korištene metrike za evaluaciju modela strojnog učenja uključuju točnost, koja pokazuje postotak točno klasificiranih primjera, preciznost koja mjeri točnost pozitivnih predikcija, odaziv koji pokazuje koliko su stvarno pozitivni primjeri ispravno identificirani, F1-mjera koja predstavlja harmonijsku sredinu preciznosti i doziva, AUC-ROC koja mjeri sposobnost modela da razlikuje klase te logaritamski gubitak koji kvantificira nesigurnost modelovih predikcija.

Kod binarne klasifikacije, Logistička regresija postiže visoku točnost (90.91%) te također postiže solidne vrijednosti za preciznost (90.55%), odziv (94.26%) i F1-mjeru (92.36%). AUC-ROC (90.25%) potvrđuje sposobnost modela da dobro razlikuje između klasa, dok je log-loss relativno nizak (0.27), što ukazuje na konzistentnost modelovih predikcija. Kod 5-razinske klasifikacije, točnost značajno pada (63.64%), što je očekivano zbog povećane složenosti zadatka. Makro prosjek preciznosti (62.88%) i F1-mjere (42.18%) ukazuje na izazove u pravilnom balansiranju između klasa, dok je log-loss (0.86) veći, što implicira veću nesigurnost modela.

Za binarnu klasifikaciju, Random Forest Classifier postiže najvišu točnost (94.29%), preciznost (93.45%), odziv (95.29%) i F1-mjeru (94.36%) u usporedbi s ostalim modelima. AUC-ROC vrijednost (93.89%) također je najviša, što ukazuje na odličnu sposobnost modela u razlikovanju klasa, dok je log-loss (0.23) najmanji, što potvrđuje njegovu robusnost. Kod 5-razinske klasifikacije, točnost se povećava na 78.95%, dok su i makro

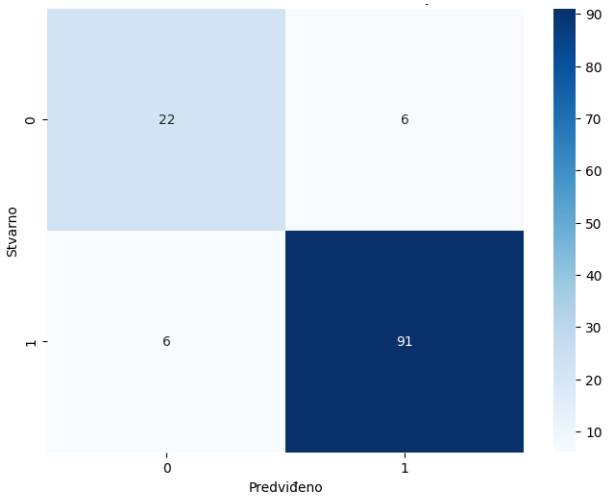
preciznost (82.48%) te F1-mjera (71.23%) značajno bolje u odnosu na ostale modele. AUC-ROC vrijednost (86.84%) potvrđuje njegovu superiornost, no log-loss (0.56) je i dalje prisutan zbog složenosti zadatka.

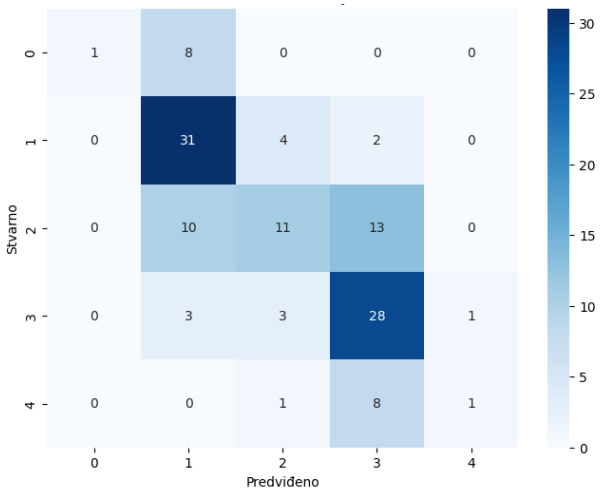
Kod binarne klasifikacije, SVM pokazuje slične performanse kao Logistička regresija, s točnošću (90.91%), preciznošću (89.31%), odzivom (95.01%) i F1-mjerom (92.49%). AUC-ROC (89.90%) je nešto niži od Random Foresta, dok je log-loss (1.03) značajno viši, što sugerira veću nesigurnost u predikcijama. Kod 5-razinske klasifikacije, točnost iznosi 73.68%, a makro preciznost (76.91%) i F1-mjera (61.42%) pokazuju bolji balans između klasa u odnosu na Logističku regresiju, no slabije rezultate u usporedbi s Random Forestom. AUC-ROC (83.55%) je solidan, dok je log-loss (1.03) i dalje visok.

Random Forest Classifier pokazuje najbolje performanse na svim zadacima, posebno u 5-razinskoj klasifikaciji gdje se ističe svojom sposobnošću balansiranja između klasa i održavanja visoke točnosti. Logistička regresija pruža solidne performanse za binarnu klasifikaciju, no ima ograničenja kod složenijih zadataka. SVM se pokazao robusnim, ali njegovi rezultati za log-loss ukazuju na nesigurnost u predikcijama, što može biti izazov kod višeklasnih problema.

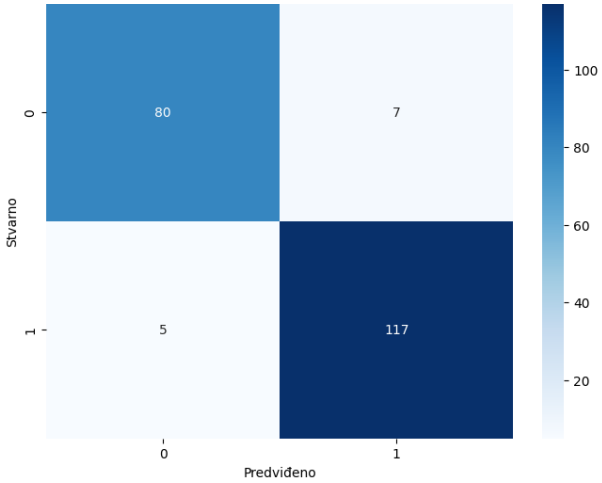
Za svaki od navedenih algoritama strojnog učenja također su izrađene matrice zabune. One predstavljaju usporedbu između stvarnih i predviđenih vrijednosti za svaku klasu te nam pomažu da bolje razumijemo ponašanje modela, uključujući gdje model uspijeva, a gdje griješi.

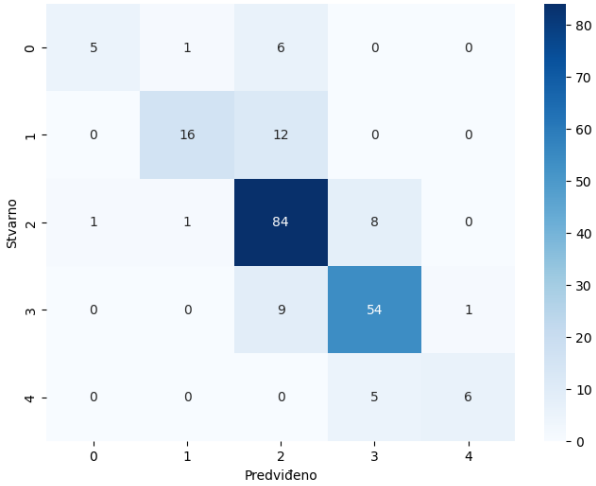
Logistička regresija



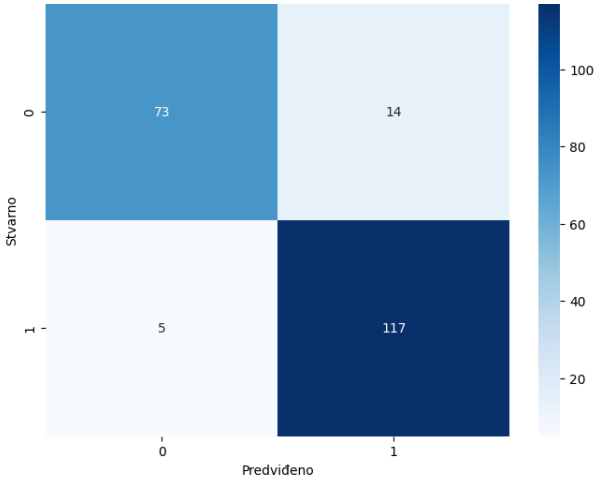


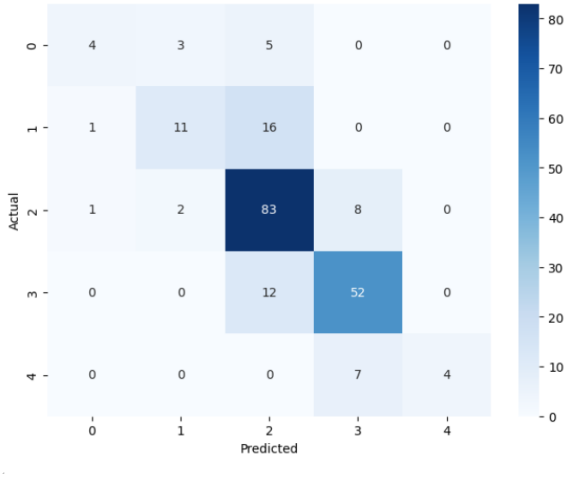
Random forest classifier





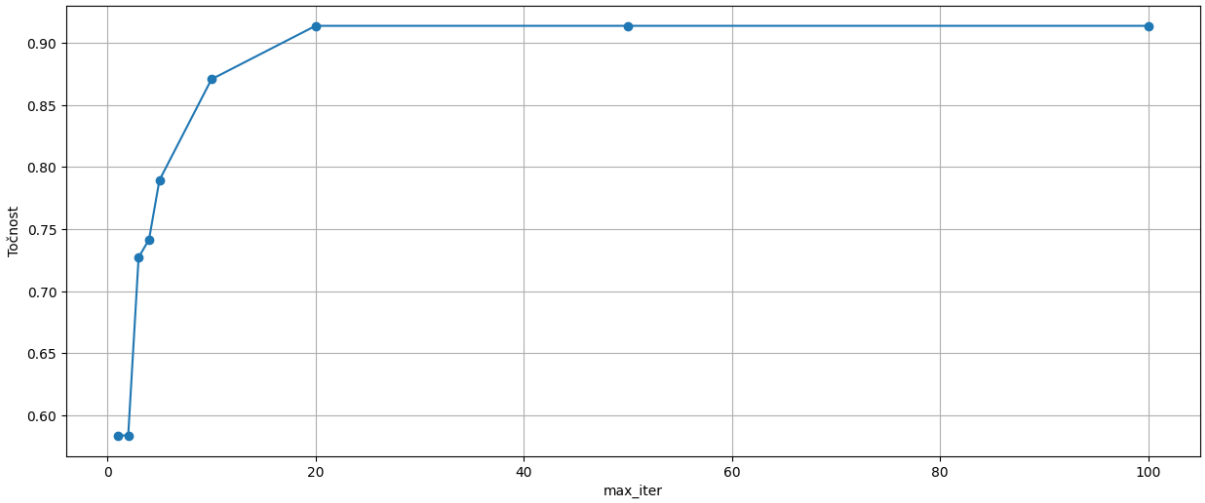
Support vector machine





Utjecaj parametara strojnog učenja na rezultate

Za analizu utjecaja parametara treniranja modela na performanse modela odabran je model binarne klasifikacije treniran pomoću algoritma logističke regresije. Analiza se provodila mijenjajući parametar max_iter koji označava maksimalan broj iteracija algoritma optimizacije te zatim mjereći točnost modela.



Promjenom maksimalnog broja iteracija za algoritam logističke regresije vidljivo je da model započinje s nižom točnošću koja se postupno povećava kako se broj iteracija povećava. U početnim fazama (mali broj iteracija), algoritam nije imao dovoljno vremena za konvergenciju prema optimalnom rješenju, što rezultira lošim performansama modela. Nakon određenog broja iteracija, točnost se stabilizira (na oko max_iter = 20) i dostiže približno konstantnu vrijednost točnosti od otprilike 90% daljnjim povećavanjem broja iteracija. Ovi rezultati ukazuju na to da je optimizacijski algoritam dosegao konvergenciju, odnosno da daljnje povećanje broja iteracija ne doprinosi značajnom poboljšanju točnosti modela

Usporedba modela za individualne i kombinirane podatke

Provedena je usporedba modela logističke regresije za predviđanje ocjena učenika iz matematike i portugalskog jezika, te kombiniranog skupa podataka koji uključuje oba predmeta. Cilj je bio utvrditi koji pristup daje bolje rezultate u binarnoj klasifikaciji.

Kombinirani podaci

```
Accuracy: 0.904
Precision: 0.9381443298969072
Recall: 0.9381443298969072
F1-Score: 0.9381443298969072
AUC-ROC: 0.8619293078055964
Log-Loss: 0.2879244318348435
```

Individualni podaci - matematika

```
Accuracy: 0.8860759493670886
Precision: 0.8809523809523809
Recall: 0.9024390243902439
F1-Score: 0.891566265060241
AUC-ROC: 0.8854300385109115
Log-Loss: 0.2808051357621935
```

Individualni podaci – portugalski jezik

```
Accuracy: 0.9076923076923077
Precision: 0.9327731092436975
Recall: 0.9652173913043478
F1-Score: 0.9487179487179487
AUC-ROC: 0.7159420289855072
Log-Loss: 0.2040725979963002
```

Model koji koristi kombinirane podatke iz matematike i portugalskog jezika postiže najveću točnost (accuracy), preciznost (precision), povrat (recall) i F1-mjeru. To ukazuje na to da kombiniranje podataka iz oba predmeta poboljšava performanse modela u predviđanju ocjena. Visoka vrijednost AUC-ROC krivulje potvrđuje dobru sposobnost modela da razlikuje prolaze od padova.

Modeli koji koriste samo podatke iz matematike ili portugalskog jezika također postižu dobre rezultate, ali nešto niže u odnosu na model koji koristi kombinirane podatke. Model za portugalski jezik ima nešto veću vrijednost odziva, što ukazuje na bolju sposobnost da identificira sve pozitivne instance. Međutim, model za matematiku ima

nešto veću vrijednost preciznosti, što ukazuje na manju vjerojatnost lažno pozitivnih klasifikacija.

Na temelju dobivenih rezultata možemo zaključiti da korištenje kombiniranih podataka iz matematike i portugalskog jezika dovodi do najboljih performansi modela. To sugerira da postoji određena povezanost između uspjeha učenika u ova dva predmeta i da kombiniranje tih podataka može pomoći u boljem predviđanju njihovih ocjena.