# Linearna regresija

Linearna regresija koristi se za modeliranje veza izmedu zavisne varijable (target ili output) te jedne ili vise nezavisnih (features ili predictors). Cilj linearne regresije je pronaci linearnu jednadbu koja najbolje predvida vrijednost zavisne varijable. Njezina upotreba primjenjuje se u zanosti o podatcima te strojnom ucenju kao i u mnogim drugim disciplinama racunalnih znanosti.

Postoji jednostavna i slozena linearna regresija. Kod jednotavne linearne regresije zavisnu varijablu usporedujemo s jednom nezavisnom, dok ju kod slozene usporedujemo s vise njih.

Implementiranje linearne regresije u Pythonu vrlo je jednostavno uz pomoc mnogih library-a kao sto su scikit-learn i statsmodeli.

Za evaluaciju modela koristimo: MSE i R-kvadrat.
MSE mjeri prosjecnu kvadratnu razliku izmedu stvarnih i predvidenih vrijednosti
R-kvadrat mjeri udio varijance u zavisnoj varijabli koji se moze predvidjeti iz nezavisnih varijabli. Krece se od 0 do 1 gdje je 1 savrsena predikcija

Takoder za evaluciju mozemo generirati razlicite tipove grafova koji ce biti analizirani malo kasnije.

Linearnom regresijom smo procijenili vrijednosti tri razlicita dataseta. Imamo podatke iz istrazivanja koji sadrze razlicite varijable kao sto su: spol, godine, posao majke, posao oca, vrijeme ucenja, prijasnje ocjene i slicno. Sve ta varijable imamo za dva razlicita predmeta: matematika i portugalski. Model testiramo zasebno na podatcima iz predmeta matematike i portugalskog, te nad grupiranim datasetom.

Prvo se treba normalizirati vrijednosti iz dataseta, jer linearna ragresija radi iskljucivo sa numerickim vrijednostima. Boolean varijable enkodirale su se label encoding-om, tj true = 1 i false = 0. Za kategoricke vrijednosti koristen je one-hot encoding koji kategoricke vrijednosti sprema u stupce te broji frenkvenciju njihova pojavljivanja. Sto se tice numerickih vrijednosti one su skalirane koristenjem min-max scaling procesa na vrijednosti izmedu 0 i 1.

Kao target value, tj. zavisnu varijablu odabrali smo G3 - ocjena iz treceg razreda, dok nam ostale vrijednosti predstavljaju feature-e. Podatke smo podijelili u dvije skupine: 80% za treniranje modela te 20% za testiranje. Zatim smo trenirali i testirali model i ovo su rezultati.

# Rezultati

Kombinirani datasetovi:

Mean Squared Error: 0.008008493099557727
R-squared: 0.7928054519878573

Matematika:

Mean Squared Error (Math): 0.014141607083078066
R-squared (Math): 0.7241341236974019

Portugalski:

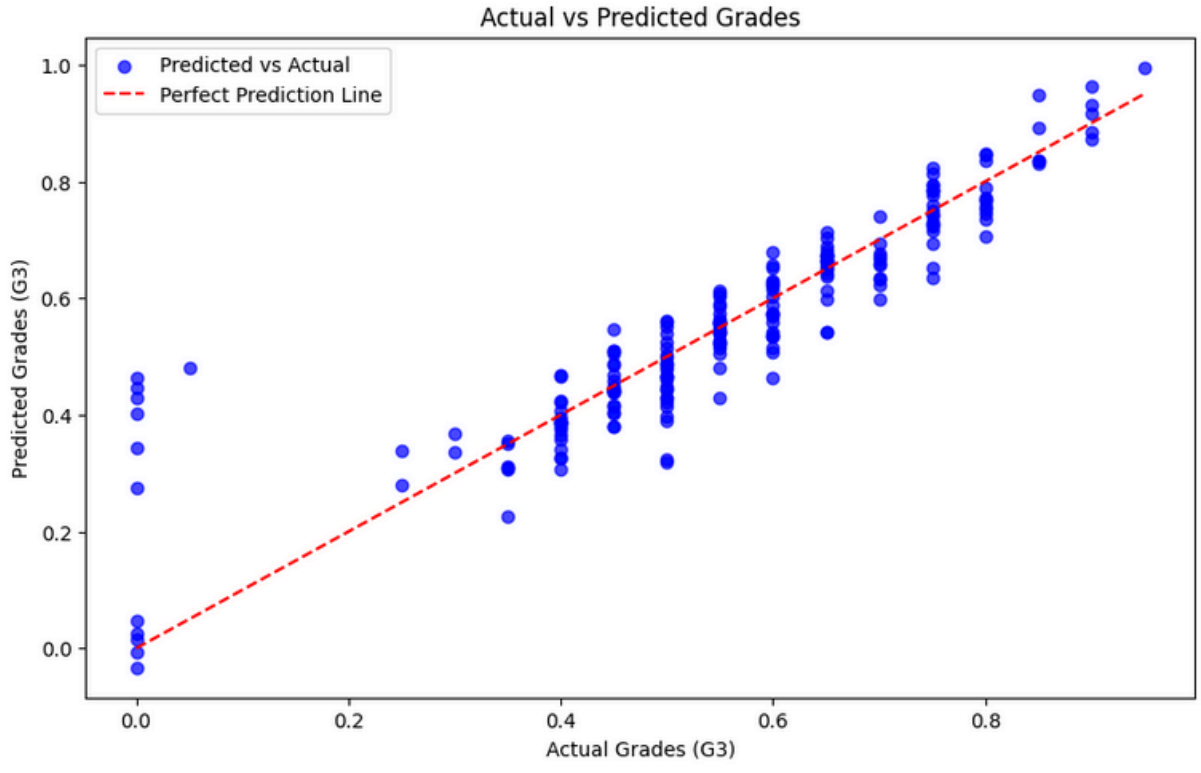
Mean Squared Error (Portuguese): 0.004088391291866 85
R-squared (Portuguese): 0.8486513286537313

Iz rezultata je vrlo jasno vidljivo da model linearne regresije daje najbolje rezultate za predvidanje ocjena iz portugalskog te najgore za matematiku, iako ni ti rezultati nisu nezadovoljavajuci.

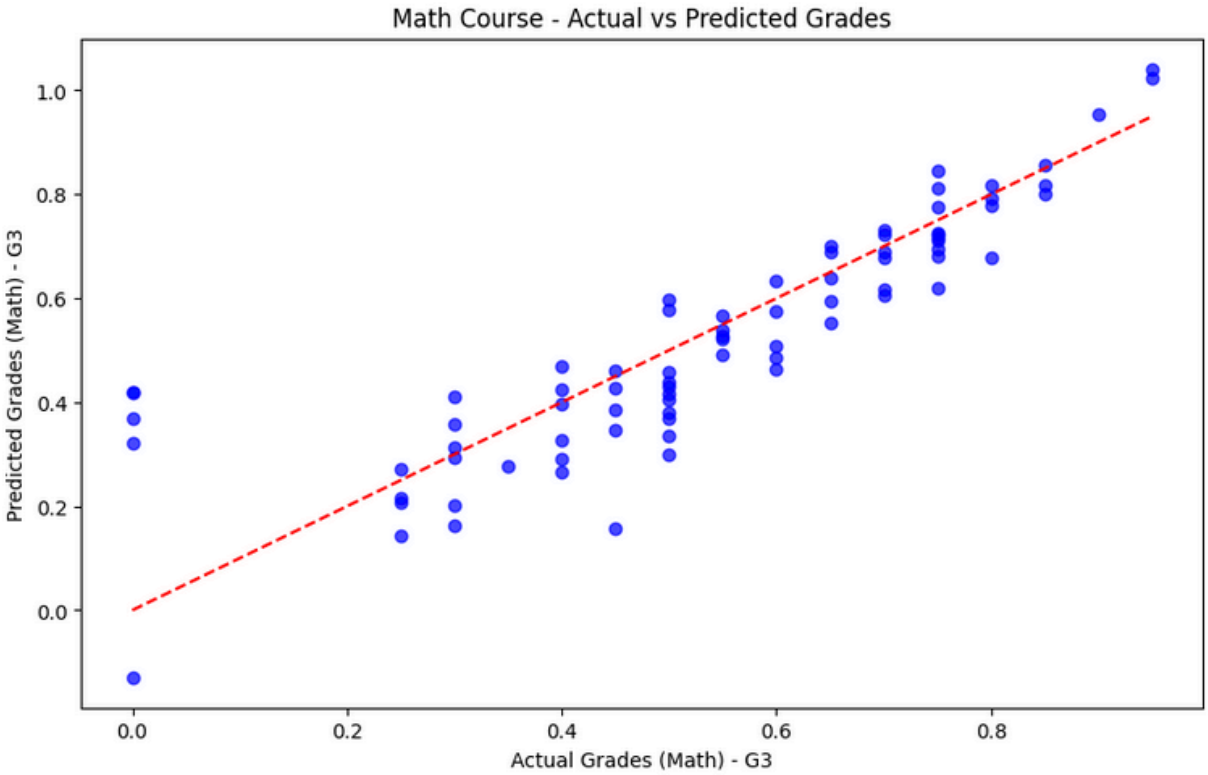
Generirali smo i nekoliko grafova koje mozemo prouciti:

1. Graf predvidenih i stvarnih vrijednosti - x-os prikazuje stvarne, a y-os predvidene vrijednosti. Crvena linija reprezentira savrseno predvidanje, tj slucaj u kojem y=x.

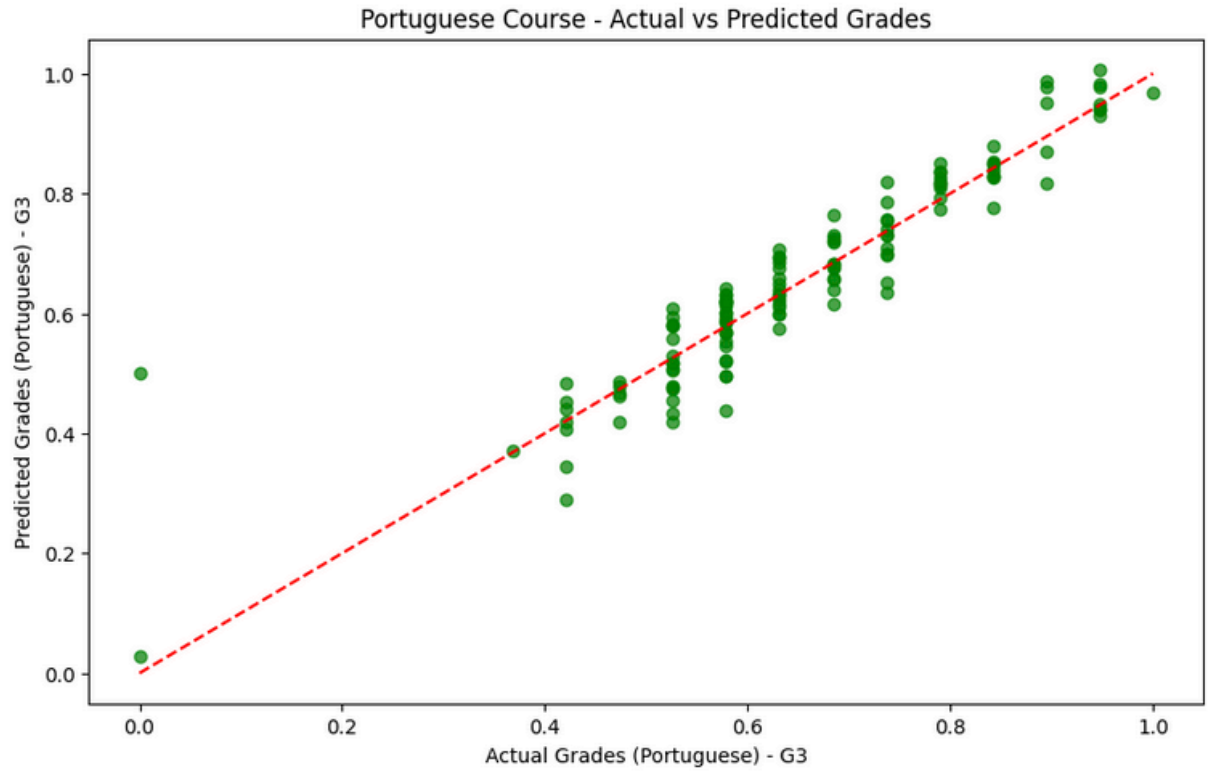
Kombinirani dataset:



Matematika:



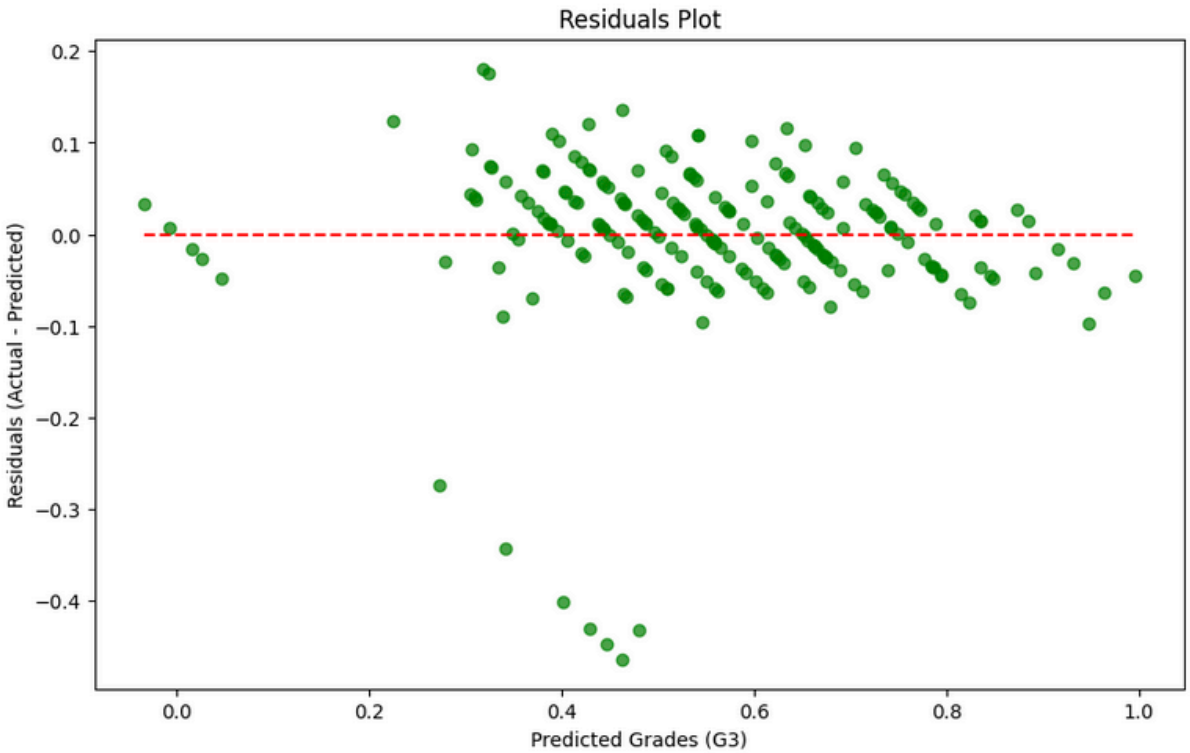

Portugalski:



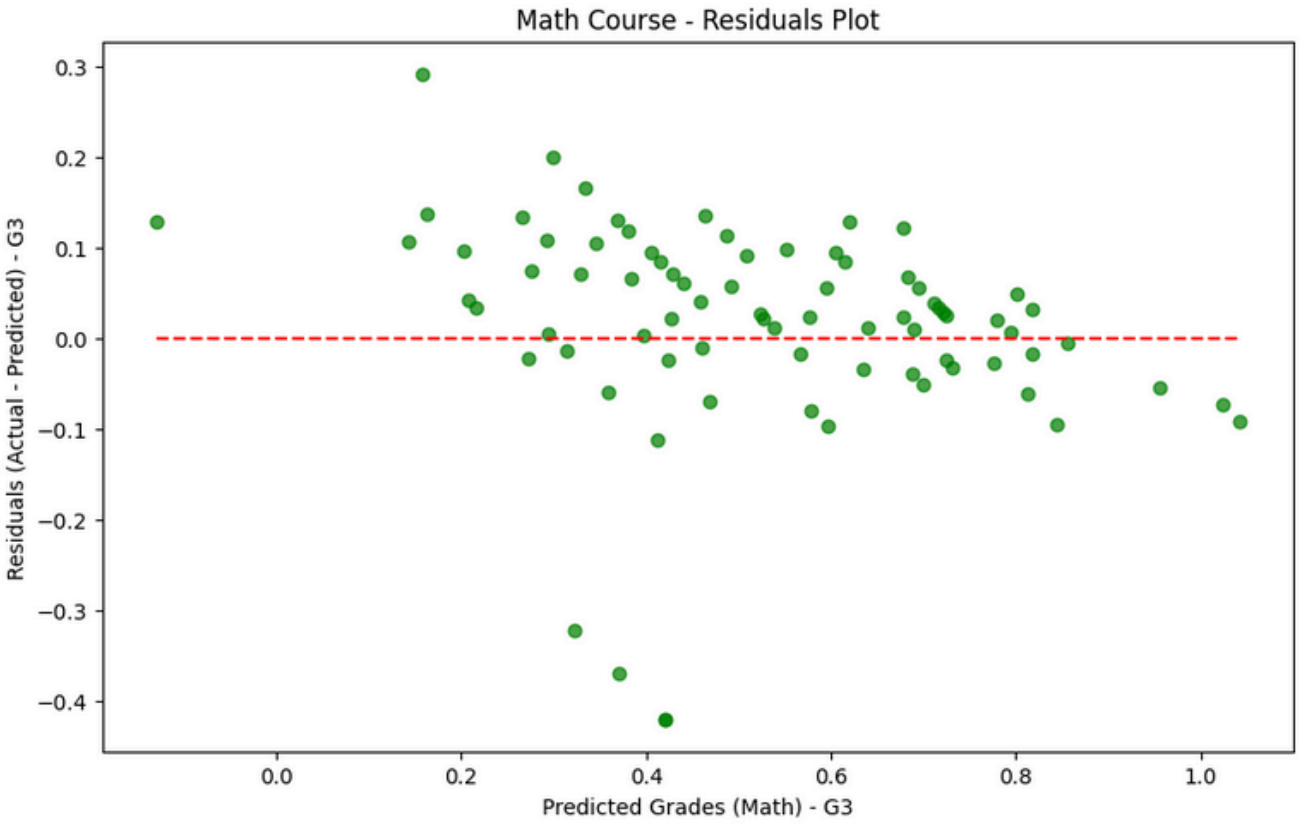
Iz gornjih grafova mozemo zakljuciti da je linearna regresija najuspjesnija za predvidanje ocjena portugalskog, dok daje malo slabije rezultate za matematiku i kombinirani dataset sto i vidimo iz odbjeglih tocki na grafovima.

2. Residual plot graf - x-os predstavlja predvidene vrijednosti, dok y-os predstavlja rezidualne (stvarna - predvidena). Zelene tocke predtavljaju rezidualnu vrijednost svakog testnog podatka, dok crvena linija (y=0, tj stvarna - predvidena=0) predstavlja savrseno predivanje.

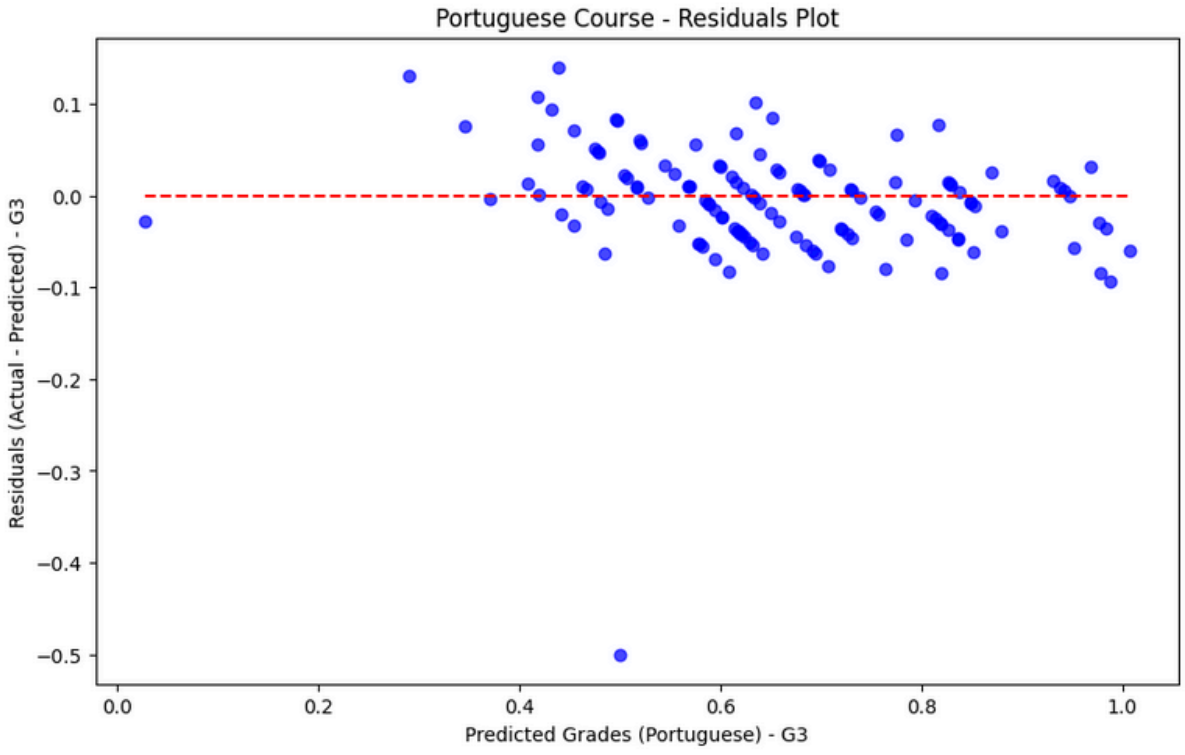
Kombinirani dataset:



Matematika:



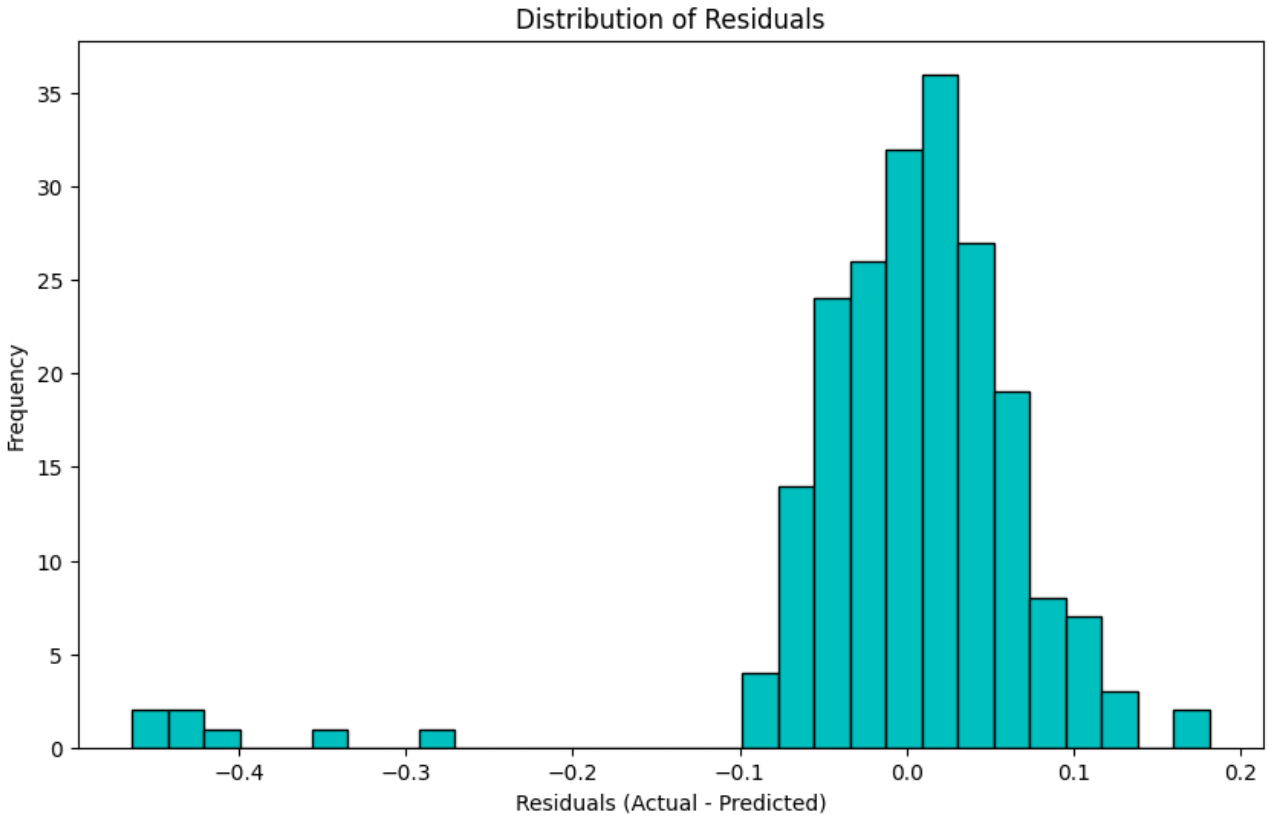

Portugalski:



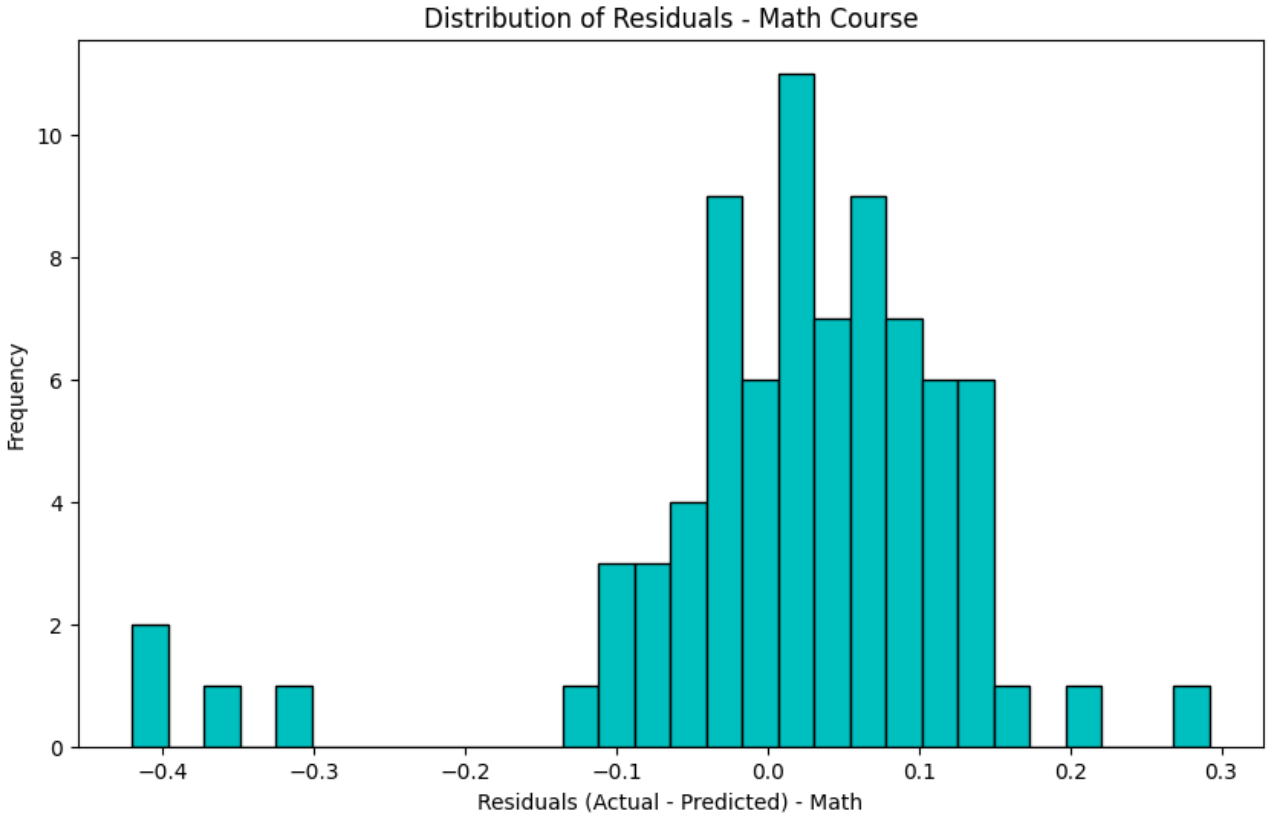
Iz ovih grafova dolazimo do istog zakljucka kao i prije. Jasno vidimo da su na grafu za predvidanje ocjena portugalskog jezika tocke najkoncentriranije oko y=0 pravca.

3. Distribucija reziduala - x-os prikazuje vrijednost reziduala (0 je savrseno predivanje), negativni rezultat na x-osi znaci da je model precijenio stvarnu vrijednost i predvidio vecu, dok pozitivni rezultat znaci da ju je podcijenio te predividio manju. Y-os prikazuje koliko puta se odredena vrijednost reziduala pojavljuje.

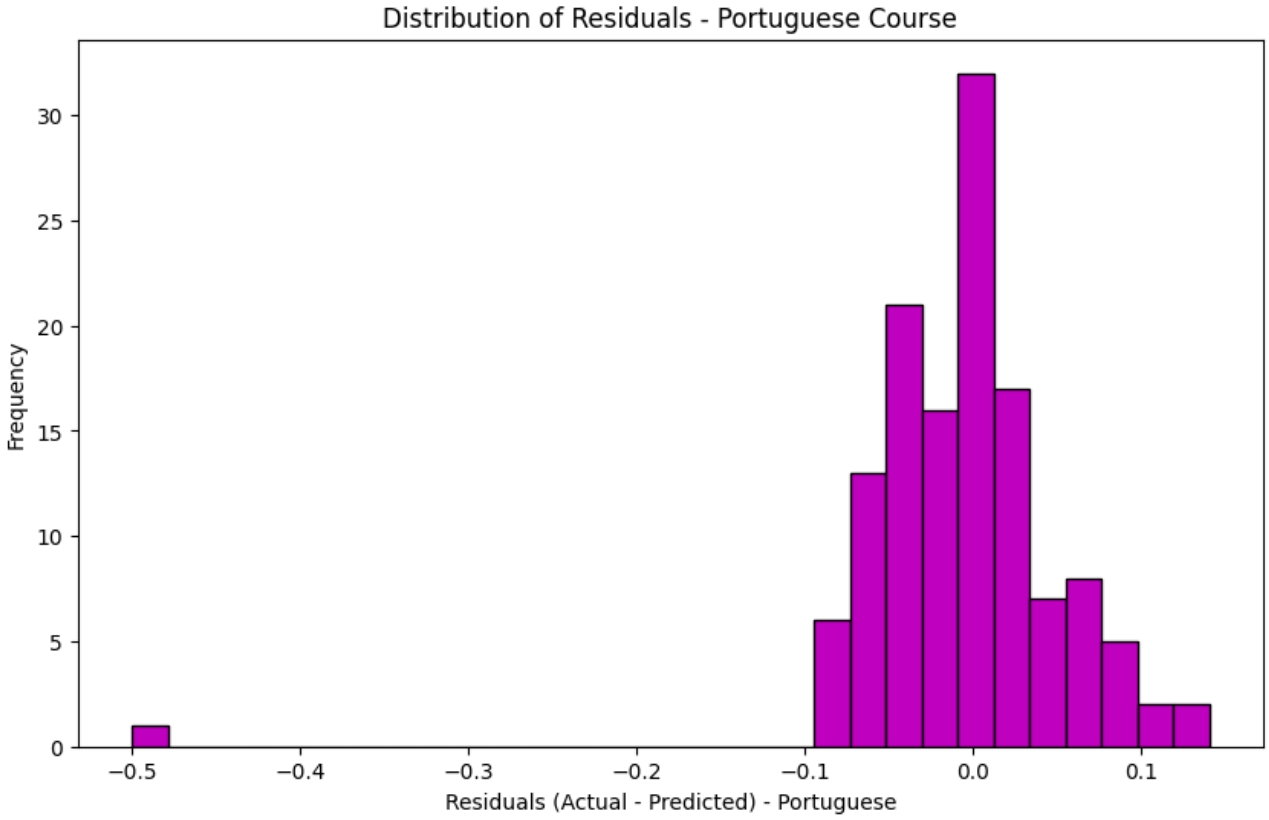
Kombinirani dataset:



Matematika:




Portugalski:



IZ grafova vidimo da su distiribucija nalikuje normalnoj u sva tri slucaja, sto je pozeljno. Takoder vrijednosti su centrirane izmedu -0.1 i 0.1 sto ukazuje na dobre razultate. Najvise odstupanja vidimo u grafu distribucije za matematiku, dok ih je uvjerljivo najmanje kod grafa portugalskog jezika.

# Random Forest Regresija

Random Forest je soup stable odluke. Koristi prosjek predvidanja svih stabala odluke kako bi predvidio vrijednost ciljane varijable. Zbog kobminacije nekoliko predvidanja smanjuje se sum i povecava tocnost.

Za svako stable odluke nasumicno se stvara podskup ponadatak iz originalnog skupa za treniranje, sto znaci da svako stablo koristi pomalo razlicite podatka. Svako stable umjesto da koristi sve varijable, nasumicno odabire neke koje ce koristiti (feature subset). Time se smanjuje korelacija medu stablima i povecava raznolikost. Savko stablo stvara svoja predvidanja i zatim se uzima prosjecna vrijednost svih rezultata.

Prilikom treniranja ovog modela moguce je podesitit odredene parametre kako bi se optimizirao model te poboljsala preformansa. Neke od njih cemo i mi podesavati (kasnije malo). Ti parametri su: n-estimators - broj stabala u sumi, Max-depth - maksimalna dubina stabla (manja dubina - manja slozenost - manji rizik od pretreniranja), min_samples_split i min_samples_leaf - minimalni broj uzoraka za podjelu cvora ili za cvor listova, max_features - maksimalan broj znacajki koje stablo moze koristiti, random_state - postavljanje sjemena za nasumicnost.

Ovaj model testiran je nad istom bazom podataka i istim kombinacijama datasetova kao i linearna regresija. Ovo su rezultati:

## Rezultati

Kombinirani setovi:

```
Mean Squared Error (MSE): 2.945248983253588
R-squared (R²): 0.8095023856915883
```

Matematika:

```
Mean Squared Error (Math): 3.751862025316455
R-squared (Math): 0.8170273895852218
```

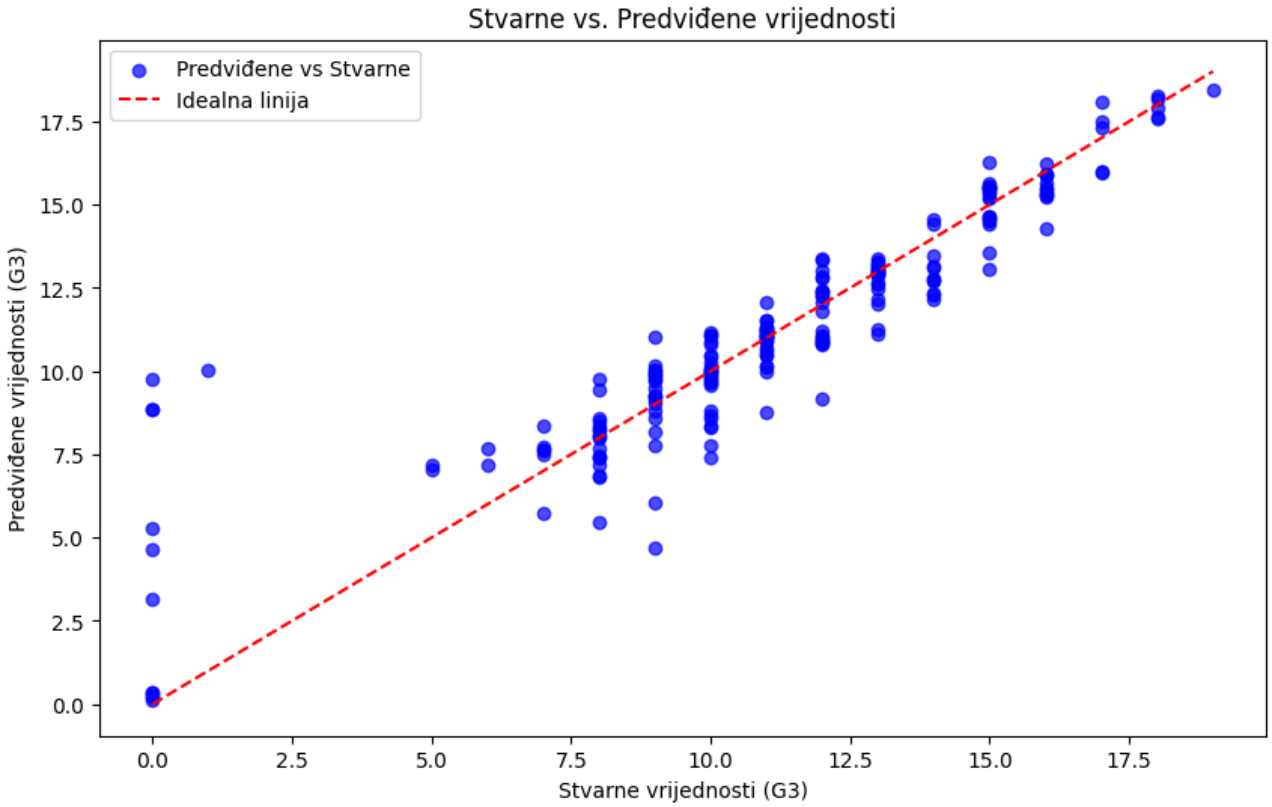
Portugalski:

```
Mean Squared Error (Portuguese): 1.557768461538462
R-squared (Portuguese): 0.8402569901215989
```

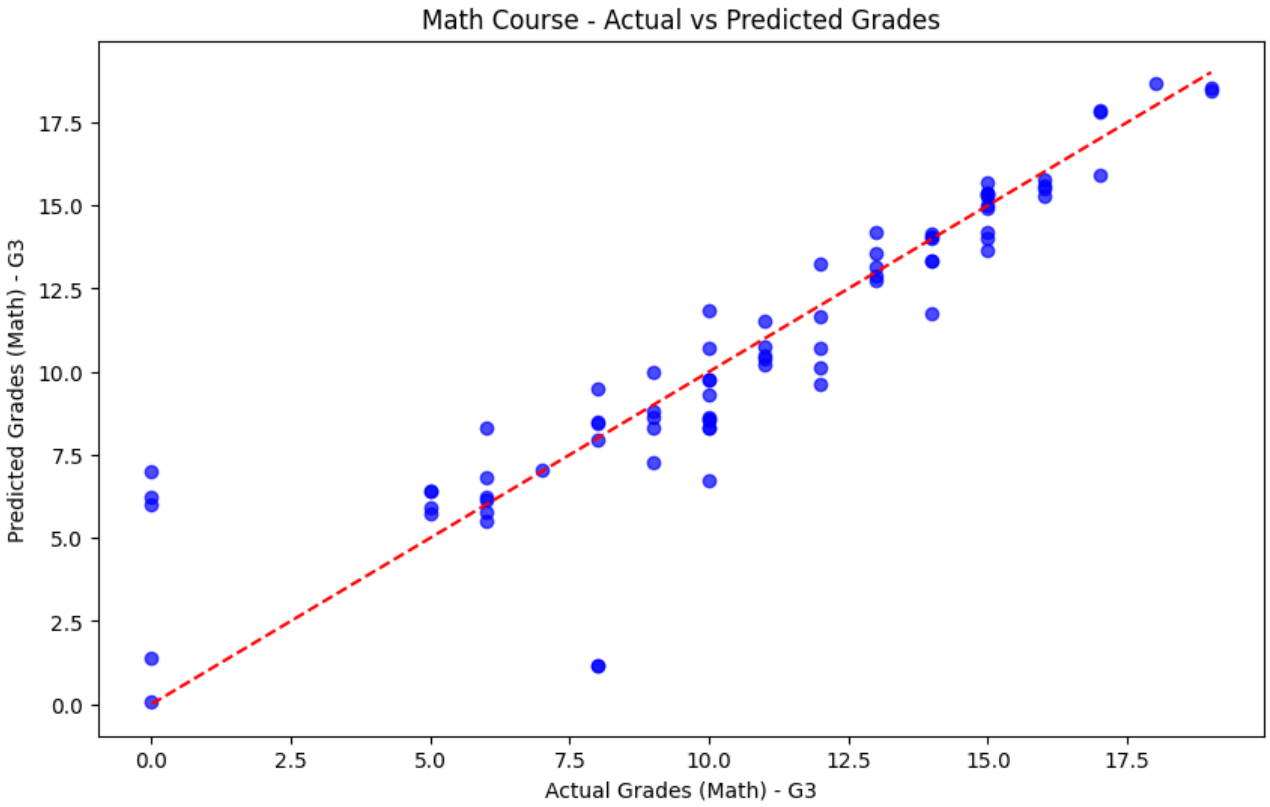
Iz ovih rezultata vidimo da je model najoptimalniji za predivanje ocjena portugalskog, a najmanje za kombinirani dataset. MSE je vrlo velik za razliku od onog kod linearne regresije sto ukazije na to da RF model daje losije rezultate od linearnog nad ovim skupovima podataka.

Grafovi:

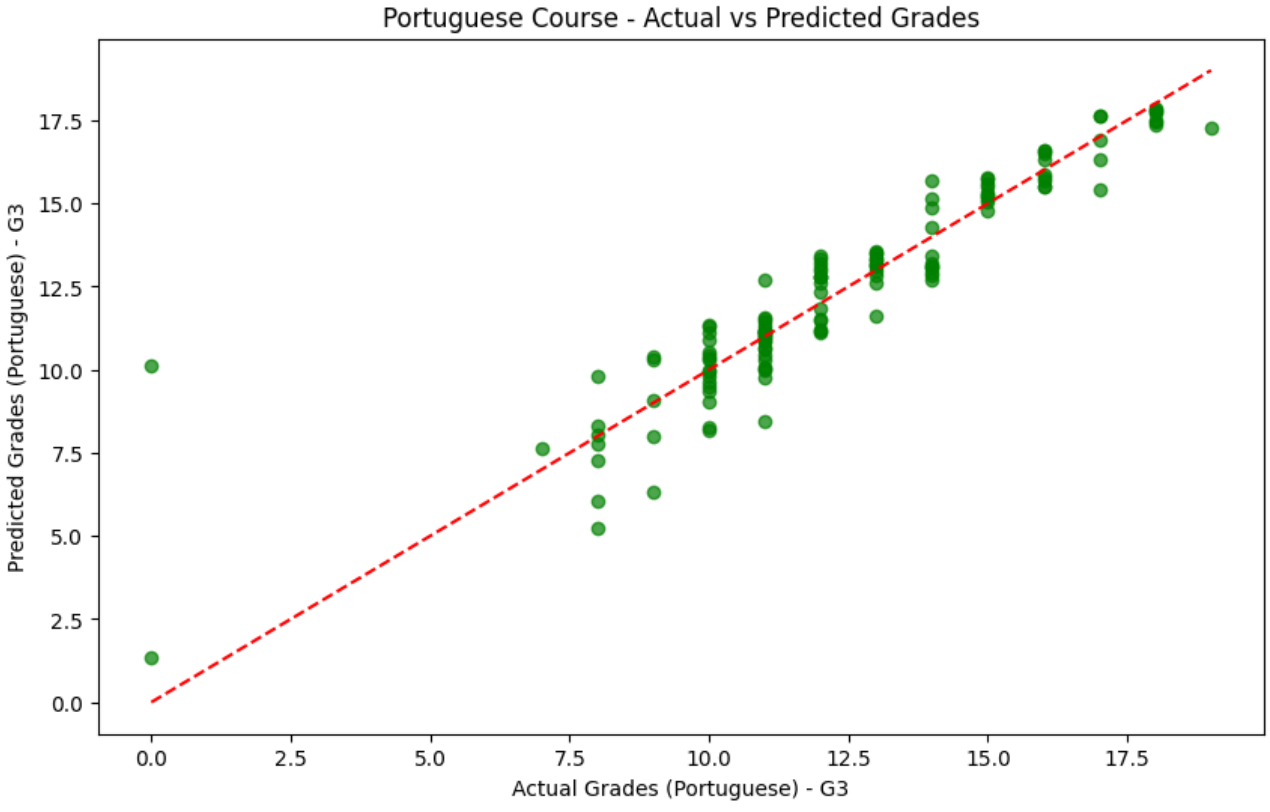
1. Predvidene i stvarne vrijednosti
   Kombinirani:



Matematika:



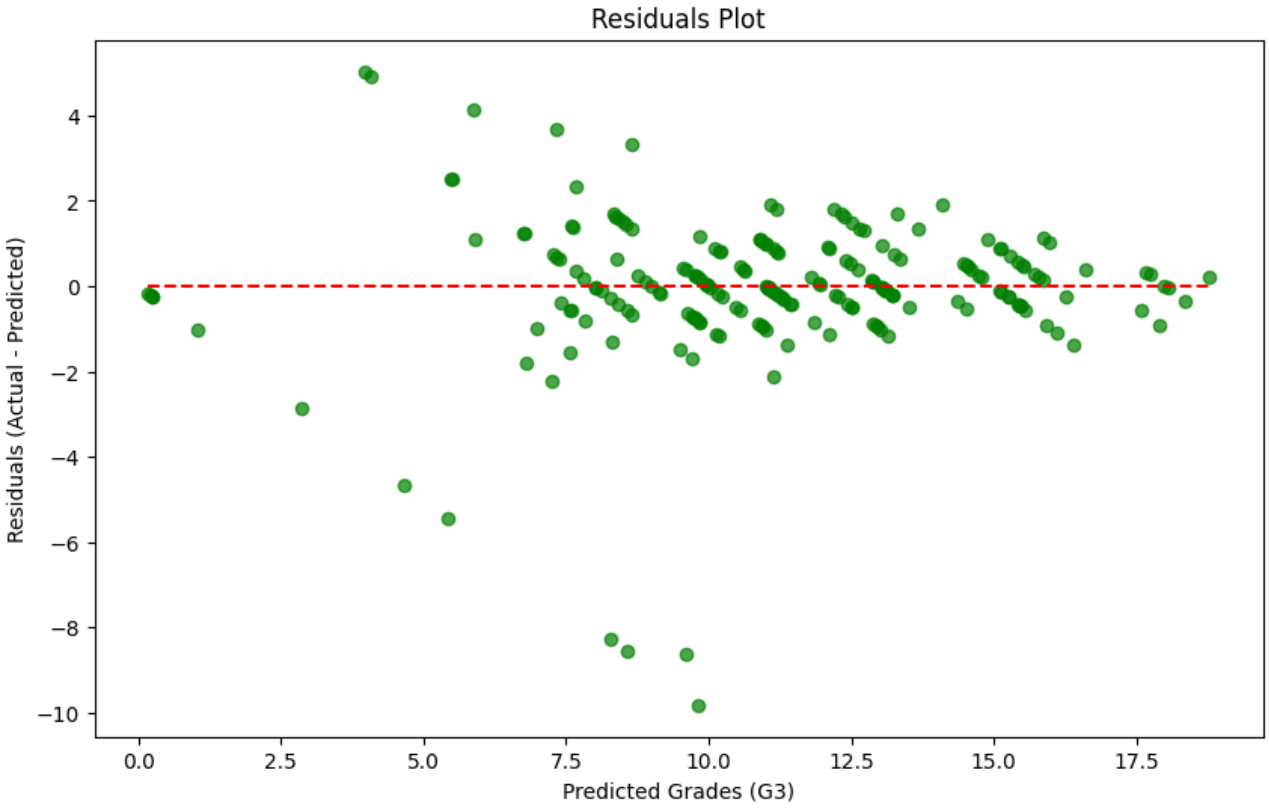

Portugalski:



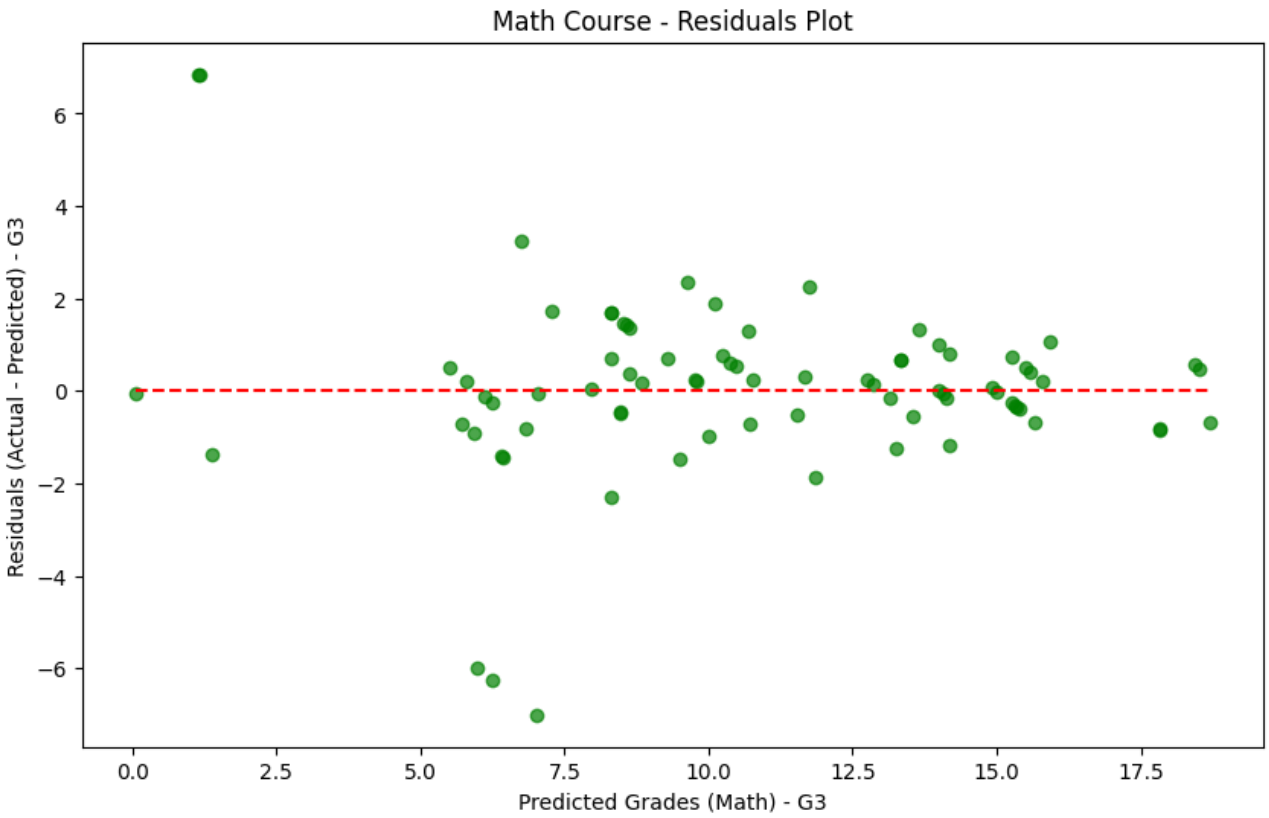
Iz gornjih grafova mozemo iscitati ono sto smo zakljucili i na temelju r-squared i mse vrijednosti. RF model najbolje radi nad podatcima za portugalski jezik, dok najlosije rezultate ima za kombinirani dataset sto vidimo iz odbjeglih tocki na grafu (tocke koje su dosta udaljene od idealne linije).

2. Rezidualni plot graf

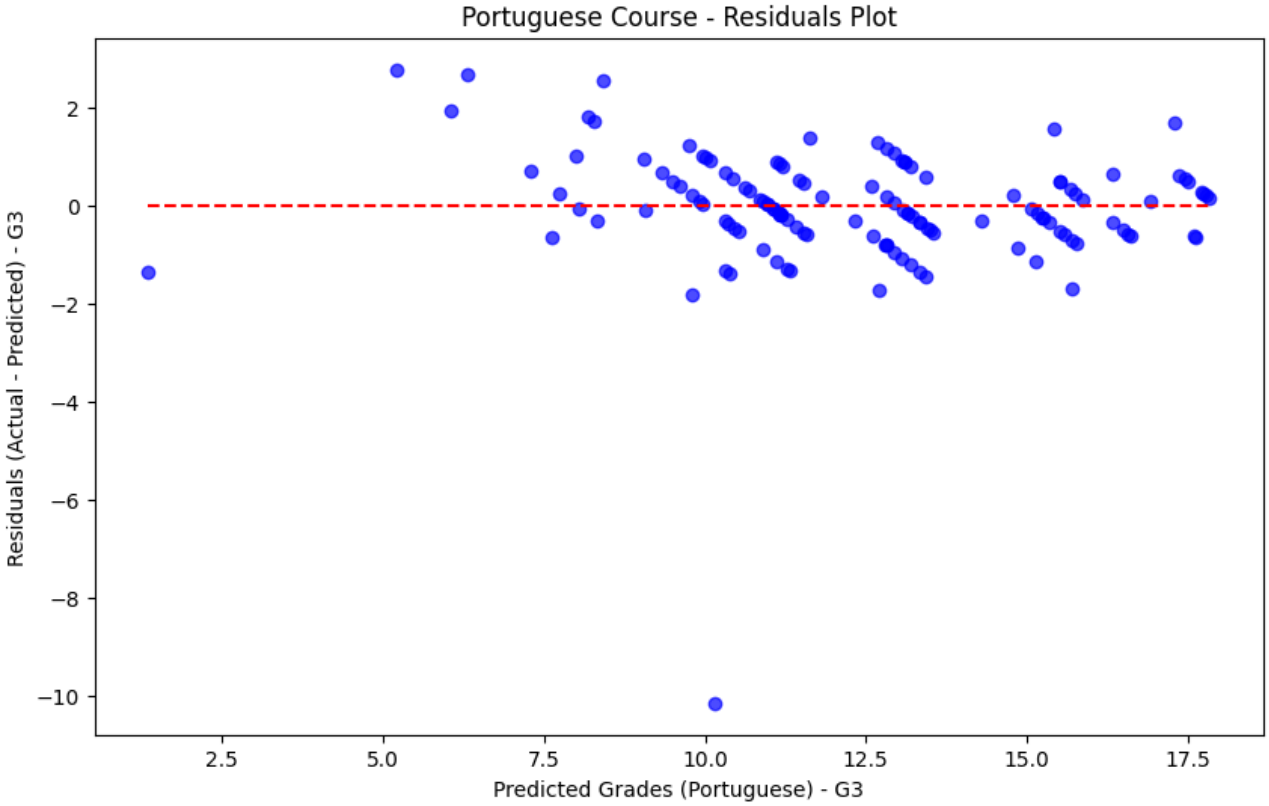
Kombinirani:



Matematika:



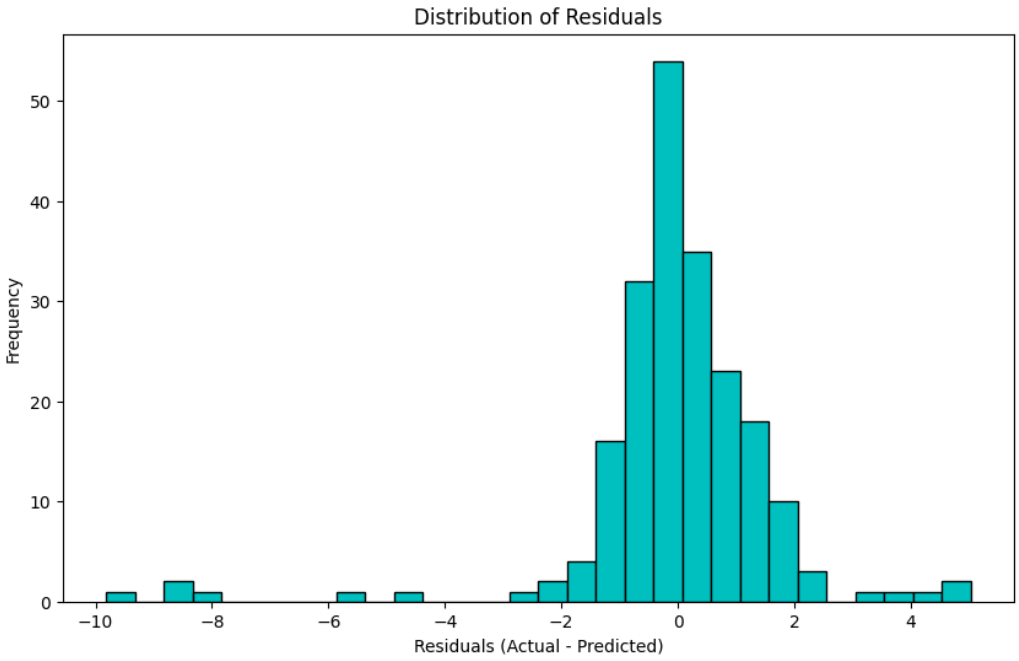

Portugalski:



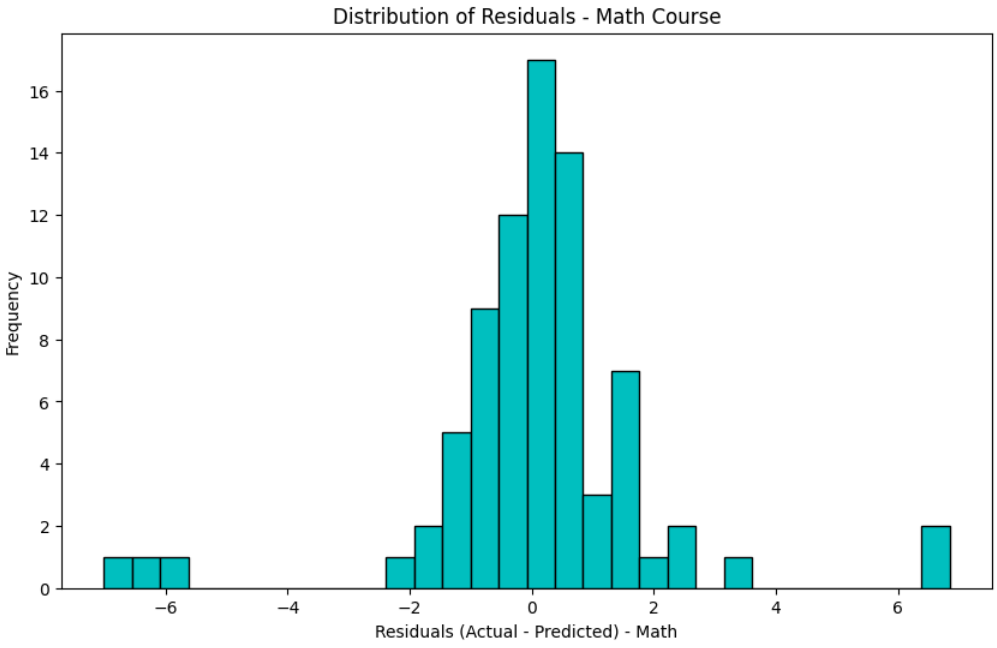
Iz gornjih grafova ponovo vidimo najvecu kolicinu vrijednosti van okoline idealne linije kod kombiniranog dataseta, dok je graf na kojem se najvise vrijednosti nalazi u blizini linije y=0 upravo onaj za predvidanje ocjena portugalskog jezika.

3. Graf distribucije reziduala

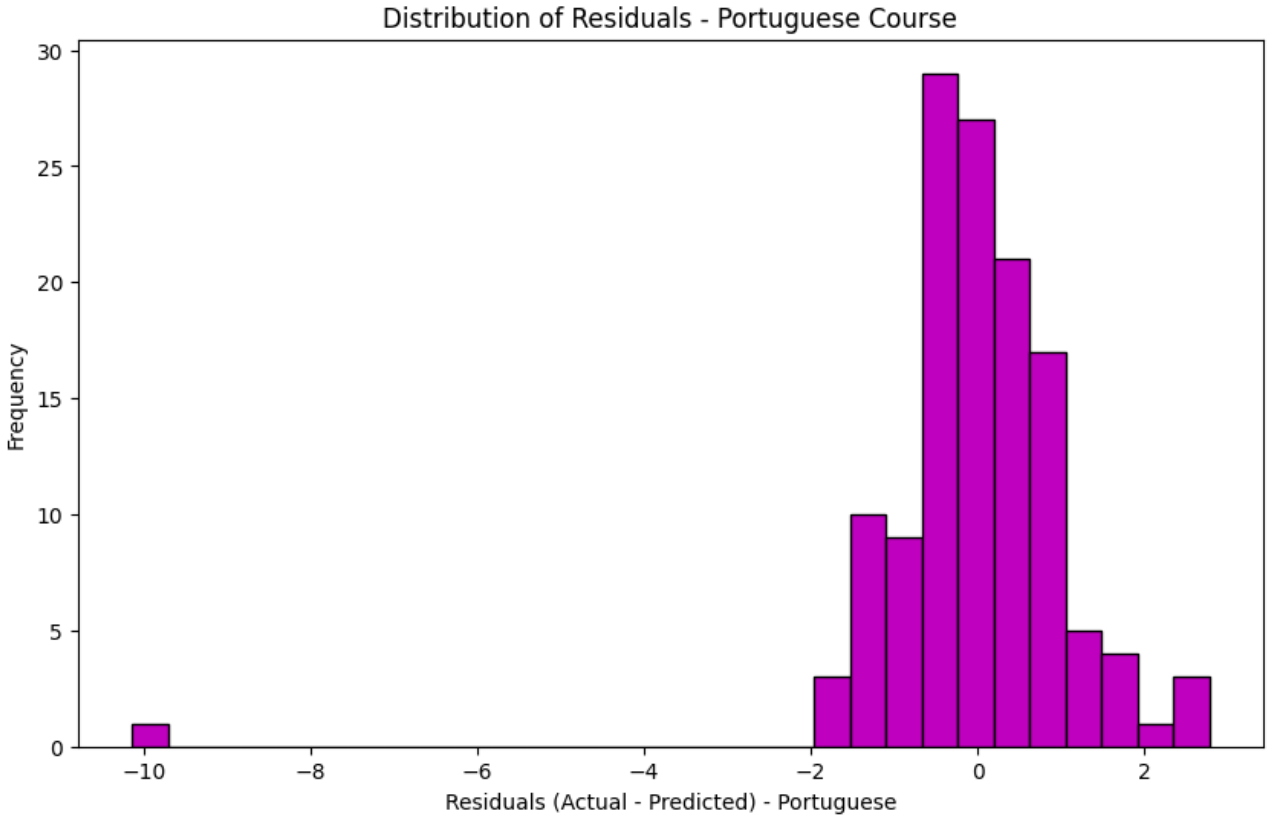
Kombinirani:




Matematika:



Portugalski:




Na grafovima distirbucije vidimo da za portugalski imamo najmanje odstupanja iz okvira vrijednosti od -2 do 2, dok ih je najvise za kombinirani dataset. Na sva tri grafa vidimo da je razdioba relativno slicna normalnoj, sto je znacajka dobrog modela predvidanja, ali za razliku od grafova linearne regresije….Nisam sigurna sad ovo mi je nesto sus ali neda mi se sad s vim bavit iskreno. Probat cu jos nes izmislit na skijanju.

# OPTIMIZACIJA

## Raspodjela setova

Kao prvi pokušaj optimizacije provedeno je testiranje modela sa različitom raspojelom dijelova za testiranje i treniranje.

# Rezultati

A) 30% testiranje, 70% treniranje

1. Linearna regresija

Kombinirani:
Mean Squared Error: 0.007669573681632214
R-squared: 0.7932225454839706

Portugalski:
Mean Squared Error (Portuguese): 0.004006583404417628
R-squared (Portuguese): 0.8692026118419498

Matematika:
Mean Squared Error (Math): 0.012482521649810929
R-squared (Math): 0.7728598737079841

2. Random Forest

Kombinirani:
Mean Squared Error (MSE): 2.8300299363057326
R-squared ($R^2$): 0.8092506797884617

Portugalski:
Mean Squared Error (Portuguese): 1.5620271794871796
R-squared (Portuguese): 0.8587442067036715

Matematika:
Mean Squared Error (Math): 3.170138655462184
R-squared (Math): 0.855785210159081

B) 40% testiranje, 60% treniranje

1. Linearna regresija
Kombinirani:
Mean Squared Error: 0.007835063970426822
R-squared: 0.7929468669879118

Matematika:
Mean Squared Error (Math): 0.012058177351698758
R-squared (Math): 0.7803192166407474

Portugalski:
Mean Squared Error (Portuguese): 0.005128177362998088
R-squared (Portuguese): 0.8225813237350839

2. Random Forest

Kombinirani:
Mean Squared Error (MSE): 2.661749282296651
R-squared ($R^2$): 0.8241483636022644

Matematika:
Mean Squared Error (Math): 3.266527848101266
R-squared (Math): 0.8512226650003193

Portugalski:
Mean Squared Error (Portuguese): 1.7832692307692308
R-squared (Portuguese): 0.8290984460659709

Iz dobivenih razultata može se zaključiti da je najbolja raspodjela datasetova ona koja koristi 30% za testiranje i 70% za treniranje. Ta raspodjela daje značajno bolje rezultate od one koja dijeli na 20/80. Kada 30/70 usporedimo pak sa raspodjelom 40/60 nije tolika razlika i poboljšanje u rezultatima. Linearna regresija čak pokazuje bolje rezultate predviđanja korištenjem 40% podataka za testiranje, a 60% za treniranje, ali kada pogledamo rezultate Random Forest regresije vidimo ipak veće poboljšanje u vrijednosti mean square errora pri korištenju 30/70 raspodjele.

## Optimizacija linearne regresije

Prvi pokušaj optimizacije bio je koristeći Feature Selection metodu. Ta metoda se bazira na odabiru određenog broja najboljih, najbitnijih varijabli te ignoriranja ostalih kako bi se izbjegla redundancija. Za odabir najboljih varijabli korištena je SelectKBest funkcija. Nakon treniranja modela dobiveni su ovi rezultati za kombinirani data set:

Feature Selection - Mean Squared Error: 0.00751429531646896
Feature Selection - R-squared: 0.8014236522477044

Iz dobivenih rezultata vidimo značajno poboljšanje u odnosu na prethodno najbolje rezultate koji su bili dobiveni za testiranje u omjeru 30/70.

Idući pokušaj je bio koristeći Polynominal regression. To je metoda kojom se dodaju ne-linearne veze između varijabli i ciljane varijable. Koristilo se podizanje na 2 razinu, što znači da su uvedene kvadratne vrijednosti varijabli i veze između njih.

Ova metoda optimizacije dala je vrlo loše rezultate. Do toga je došlo zbog dodavanja velikog broja novih varijabli koje su sa sobom donijele veliku količinu redundancije. Također, velik broj novonastalih varijabli ne nosi nikakve korisne informacije, a isto tako dodavanje ne-linearnih varijabli u linearni model nije preporučena metoda optimizacije što smo ovime i dokazali. Rezultati:

Polynomial Regression - Mean Squared Error: 0.3808770944105157
Polynomial Regression - R-squared: -9.065239542127454

## Optimizacija Random Forest regresije

Kao prva metoda optimizacije korišten je Hyperparametar tuning koristeći GridSearchCV. RF regresija sadrži nekoliko parametara koji utječu na uspješnost modela: n_estimators, max_depth, min_samples_split, min_samples_leaf. GridSearchCV je tehnika kojom se traži najbolja kombinacija vrijednosti tih parametara. Rezultati ove metode:

Best Parameters: {'max_depth': 20, 'max_features': None, 'min_samples_leaf': 4, 'min_samples_split': 10, 'n_estimators': 200}
Best $R^2$ Score: 0.8539178622817725
Optimized Mean Squared Error: 2.588741604628627
Optimized R-squared: 0.828971702777336

Iz rezultata vidimo da je optimalna dubima stabla 20. To znači da kada stablo pri treniranju modela dosegne dubinu 20, prestaje s daljnjim dijeljenjem/grananjem. Optimalna maksimalna količina varijabli je ‘None’ što znači da svako stablo može koristiti sve raspoložive varijable seta podataka. To može biti korisno kada se radi na velikim bazama podataka, no nije idealno za manje količine. Minimalna količina uzorka za list je 4, što znači da će čvor stabla postati list samo ako ima barem 4 uzorka. Minimalna količina uzorka za odvajanje je 10. Taj parametae predstavlja najmanju potrebnu količinu uzorka za razdvajanje unutarnjeg čvora stabla. N_estimators je 200 i on predstavlja broj stabla koja se generiraju tijekom treniranja modela.
Mean Squared Error i r-quared vrijednosti su optimalnije u odnosu na one prije optimizacije modela ovom metodom.

Druga korištena metoda je Feature Selection, isto kao i kod optimizacije modela linearne regresije. Korištenjem ove metode dobiveni su slabiji rezultati optimizacije od GridSearchCV metode:

Feature Selection - Mean Squared Error: 3.3566318449312535
Feature Selection - R-squared: 0.7782401195177157

Dobiveni rezultati su također gori od treniranja modela raspodjelom 30/70, što je bila uspješna metoda optimizacije.

Zaključak:

Najbolji rezultati za model linearne regresije dobiveni su nakon optimizacije korištenjem Feature Selection metode nad podjelom podataka u omjeru 30/70. Ista metod korištena sa RF regresijom ne daje dobre rezultate. Naime, za optimizaciju Random Forest regresije najbolji rezultati su dobiveni korištenjem GridSearch metode, također nam podjelom 30/70 jer se upravo ta podjela prethodno pokazala najpovoljnijom za oba modela.